


Mobilitas Modern Kota New York: Analisis Data FHV Trip Records -Maret 2025-

Presented By

Nabila Hulwana Zuhud
Kelas Work | 2029

FINAL PROJECT DATA ANALYST
SMARTPATH



Daftar Isi

1. Data Overview

2. Scope of Problem

3. Problem Formulation

4. Metodologi

5. Data Source

6. Analysis Result

Cleaning dan eksplorasi data with python & SQL

[Klik disini!](#)

7. Data Visualization & Dashboard

Visualization with Tableau

[Klik disini!](#)

8. Insight & Recommendation

Data Overview

New York City Taxi and **Limousine Commission (TLC)** adalah lembaga pemerintah yang bertanggung jawab atas perizinan dan pengawasan layanan transportasi seperti taksi kuning, taksi hijau (taxis), dan For-Hire Vehicles (FHV) di Kota New York. Sejak tahun 2015, TLC mulai mengumpulkan dan merilis **data perjalanan kendaraan FHV** dari berbagai perusahaan berbasis aplikasi seperti Uber, Lyft, Via, dan Juno.

Dengan memanfaatkan data real dari trip FHV pada **Maret 2025**, akan dianalisis data perjalanan FHV berdasarkan waktu dan lokasi, mengevaluasi efisiensi layanan, .Serta akan dibangun model machine learning untuk memprediksi lamanya durasi perjalanan, serta menyajikan insight melalui dashboard interaktif

2 Two main companies with HVFHS licenses in NYC: **Uber and Lyft**.

600k + Average Trips by FHV (Uber and Lyft) a day



Scope of Problem

- ✓ Data perjalanan FHV bulan Maret 2025, mencakup waktu penjemputan, lokasi, durasi, jarak tempuh, serta tarif dan biaya perjalanan dan lainnya,
- ✓ Data company informasi perusahaan penyedia layanan FHV yang menunjukkan hubungan antara lisensi dan nama perusahaan
- ✓ Data yang mencerminkan company, trips dan zona yang sangat besar adalah tantangan pengelolaan mobilitas perkotaan
- ✓ Data **zona** lokasi yang berisi informasi ID unik dari zona, nama wilayah, nama zona (borough), dan wilayah layanan (service zone).
- ✓ Proses pengolahan data mencakup:
 - Eksplorasi dan pembersihan data (**data cleaning**).
 - **Query SQL** untuk menjawab pertanyaan bisnis.
 - Analisis statistik dan korelasi menggunakan **Python**.
 - Visualisasi performa layanan harian menggunakan **Tableau**.
 - **Pemodelan prediktif** durasi perjalanan menggunakan **Machine Learning**.




Problem Formulation

- ? Bagaimana **pola distribusi** jumlah perjalanan, durasi perjalanan, hingga total pendapatan layanan FHV harian?
- ? Bagaimana sebaran **zona paling sibuk** penjemputan dan pengantaran?
- ? Bagaimana cara membangun **model untuk memprediksi durasi perjalanan (trip time)** berdasarkan data historis menggunakan machine learning?
- ? Apakah terdapat **ketimpangan** antara jumlah trip dan durasi nya? Atau ketimpangan antara jarak trip dengan driver pay?
- ? Bagaimana **tren perkembangan jumlah perjalanan** dari hari ke hari dan dampaknya terhadap transportasi umum di NYC?
- ? Bagaimana cara menyajikan **insight** dalam bentuk **visualisasi interaktif** yang dapat membantu pengambilan keputusan operasional?



Metodologi



Data Source

Data nyc_taxi.db

FHV' Trips in New York at 2025

Data yang digunakan berasal dari New York City Taxi and Limousine Commission (TLC). Dataset ini merupakan rekaman perjalanan For-Hire Vehicles (FHV) untuk bulan Maret 2025, yang telah difilter dan disiapkan ulang oleh Lingga Aji Andika.



Website NYC Taxi & Limousine Commisioonn (TLC)

<https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>



Analysis Result

Data Cleaning & Tampilan CSV file

	A	B	C	D	E	F	G	H	I	J	
1	hvfhs_license_num	dispatching_base_num	request_datetime	on_scene_datetime	pickup_datetime	dropoff_datetime	PULocationID	DOLocationID	trip_miles	trip_time	base_passenger
2	HV0003	B03404	01/03/2025 00:48	01/03/2025 00:54	01/03/2025 00:55	01/03/2025 01:17	43	212	738	1299	
3	HV0003	B03404	01/03/2025 00:23	01/03/2025 00:31	01/03/2025 00:33	01/03/2025 00:45	161	238	323	720	
4	HV0003	B03404	01/03/2025 00:35	01/03/2025 00:38	01/03/2025 00:39	01/03/2025 00:54	161	107	276	936	
5	HV0003	B03404	28/02/2025 23:58	01/03/2025 00:02	01/03/2025 00:02	01/03/2025 00:17	161	113	24	891	
6	HV0003	B03404	01/03/2025 00:41	01/03/2025 00:43	01/03/2025 00:44	01/03/2025 01:01	161	145	33	990	
7	HV0003	B03404	01/03/2025 00:02	01/03/2025 00:06	01/03/2025 00:07	01/03/2025 00:29	230	75	406	1322	
8	HV0003	B03404	01/03/2025 00:06	01/03/2025 00:11	01/03/2025 00:12	01/03/2025 00:45	161	252	1464	1984	
9	HV0003	B03404	01/03/2025 00:08	01/03/2025 00:13	01/03/2025 00:13	01/03/2025 00:48	161	189	735	2115	
10	HV0003	B03404	01/03/2025 00:42	01/03/2025 00:46	01/03/2025 00:46	01/03/2025 01:10	161	97	947	1398	
11	HV0003	B03404	01/03/2025 00:41	01/03/2025 00:47	01/03/2025 00:48	01/03/2025 01:00	230	141	228	759	
12	HV0003	B03404	01/03/2025 00:06	01/03/2025 00:16	01/03/2025 00:16	01/03/2025 00:29	230	90	178	771	
13	HV0003	B03404	28/02/2025 23:58	01/03/2025 00:08	01/03/2025 00:08	01/03/2025 00:42	161	228	1158	2049	
14	HV0003	B03404	01/03/2025 00:12	01/03/2025 00:17	01/03/2025 00:17	01/03/2025 01:21	161	265	422	3819	
15	HV0003	B03404	01/03/2025 00:05	01/03/2025 00:08	01/03/2025 00:09	01/03/2025 00:33	230	265	1047	1442	
16	HV0003	B03404	28/02/2025 23:55	01/03/2025 00:01	01/03/2025 00:01	01/03/2025 00:35	230	181	911	2048	
17	HV0003	B03404	28/02/2025 23:55	01/03/2025 00:02	01/03/2025 00:03	01/03/2025 00:24	230	260	667	1270	
18	HV0003	B03404	01/03/2025 00:06	01/03/2025 00:10	01/03/2025 00:12	01/03/2025 00:36	161	148	337	1467	
19	HV0003	B03404	01/03/2025 00:19	01/03/2025 00:20	01/03/2025 00:20	01/03/2025 00:33	161	140	24	761	
20	HV0003	B03404	01/03/2025 00:09	01/03/2025 00:18	01/03/2025 00:19	01/03/2025 01:03	161	22	1596	2654	
21	HV0003	B03404	28/02/2025 23:59	01/03/2025 00:04	01/03/2025 00:05	01/03/2025 00:10	230	164	96	340	

- Proses Pembersihan Data: Kami memastikan data bersih dari nilai yang hilang (Missing values), data duplikat, dan anomali logis.
- Anomali Utama: Menghapus data dengan nilai negatif pada kolom driver_pay dan trip_miles, serta menghapus outlier yang tidak masuk akal.
- Status Data: Data yang digunakan sudah bersih dan tidak ada sel kosong.

Analysis Result

Hasil Analisis : Data Insight With SQL

1. Top 5 Trip dengan pendapatan Tertinggi pada 1 Maret 2025

	pickup_datetime	PULocationID	DOLocationID	trip_miles	total_pendapatan
0	2025-03-01 00:05:13	161	265	48.79	337.05
1	2025-03-01 20:12:16	161	265	26.37	322.86
2	2025-03-01 23:19:26	230	265	56.08	321.68
3	2025-03-01 14:35:54	161	265	30.90	289.61
4	2025-03-01 23:32:37	161	265	53.56	284.11

2. Peringkat zona pickup dengan volume terbanyak

	Borough	Zone	PICKUP_NUMBER
0	Manhattan	Times Sq/Theatre District	247868
1	Manhattan	Midtown Center	239306
2	Manhattan	Midtown North	162589
3	Manhattan	Central Park	25759

3. Top 5 tujuan akhir

	destination_borough	destination_zone	trip_count
0	None	Outside of NYC	57540
1	Queens	LaGuardia Airport	39526
2	Manhattan	East Chelsea	19446
3	Manhattan	West Chelsea/Hudson Yards	19052
4	Queens	JFK Airport	18841

4. Waktu tunggu rata-rata

	Zone	avg_wait_time_minutes
0	Times Sq/Theatre District	3.619810
1	Midtown Center	3.491566
2	Central Park	3.059500
3	Midtown North	2.877526

Analysis Result

Hasil Analisis : Data Insight With SQL

5. Waktu tersibuk per minggu

	day_of_week	number_of_trips
0	Wednesday	106107
1	Thursday	105190
2	Monday	102068
3	Saturday	97903
4	Tuesday	94680
5	Friday	85459
6	Sunday	84115

7. Top 5 paid driver berdasarkan App

	app_company	dispatching_base_num	total_pay
0	Lyft	B03406	8.239138e+06
1	Uber	B03404	4.142389e+08

6. Perbandingan *rush hour* pagi vs petang

	time_period	number_of_trips	average_fare
0	Evening Rush	123660	40.571593
1	Morning Rush	56436	40.569419

8. Anomali dalam tarif



	pickup_borough	dropoff_borough	base_passenger_fare	avg_fare_for_route	fare_difference
0	Manhattan	None	1156.00	96.260139	1059.739861
1	Manhattan	None	969.49	96.260139	873.229861
2	Manhattan	None	896.06	96.260139	799.799861
3	Manhattan	None	890.98	96.260139	794.719861
4	Manhattan	None	865.90	96.260139	769.639861
5	Manhattan	None	848.91	96.260139	752.649861
6	Manhattan	None	844.36	96.260139	748.099861
7	Manhattan	None	746.45	96.260139	650.189861
8	Manhattan	None	738.79	96.260139	642.529861
9	Manhattan	None	726.35	96.260139	630.089861

Analysis Result

Hasil Analisis Python dan SQL : Eksplorasi Data dan Analisis Regresi

9. Mengukur Waktu Tanggap Pengemudi

```
Ditemukan 58 baris di mana pickup_datetime < on_scene_datetime. Memperbaiki dengan menambah 1 hari.  
Rata-rata Waktu Respons (Semua Perjalanan): 1.21 menit  
  
[INFO] Perbandingan Rata-rata Waktu Respons Berdasarkan Permintaan WAV:  
- Rata-rata Waktu Respons untuk permintaan WAV ('Y'): 2.63 menit  
- Rata-rata Waktu Respons untuk Non-WAV ('N'): 1.20 menit  
  
[INFO] Ringkasan Perbandingan:  
wav_request_flag  avg_response_time  
0                Y          2.631502  
1                N          1.203133  
  
[INFO] Tampilan 5 baris pertama dari DataFrame analisis:  
on_scene_datetime  pickup_datetime  response_time  wav_request_flag  
0 2025-03-01 00:54:57 2025-03-01 00:55:22      0.416667                N  
2 2025-03-01 00:31:39 2025-03-01 00:33:19      1.666667                N  
3 2025-03-01 00:38:59 2025-03-01 00:39:15      0.266667                N  
4 2025-03-01 00:02:21 2025-03-01 00:02:35      0.233333                N  
5 2025-03-01 00:43:48 2025-03-01 00:44:47      0.983333                N
```


10. Analisis Keberhasilan Shared Ride per Perusahaan

```
App Company Affiliation  shared_requests  matched_shared  \  
0                Uber          154470          97350  
  
match_success_ratio_%  
0                63.021946  
  
Diketahui bahwa dengan requested 154.440 permintaan shared ride hanya 97.350 yang dapat dipasang.
```


11. Evaluasi Layanan Kendaraan Aksesibel (WAV)

```
App Company Affiliation  wav_requests  wav_matched  match_rate_%  
0                Lyft           634           634          100.0  
1                Uber          27900          27900          100.0  
  
[TERENDAH] Perusahaan dengan tingkat pemenuhan WAV terendah: Lyft
```

12. Analisis Zona Lokasi Penjemputan



13. Analisis Kolerasi Jarak dan Pembayaran Pengemudi





Machine Learning


Model Trip Time Prediction dengan supervised learning

Pemilihan Model:

- **Linear Regression** digunakan sebagai baseline model yang sederhana.
- **Random Forest Regression** dipilih untuk menangkap hubungan yang lebih kompleks (non-linear) antar fitur.

Fitur yang Digunakan: Sejumlah fitur, seperti trip_miles, PULocationID, DOLocationID, dan pickup_hour, dipersiapkan untuk melatih model. Matriks korelasi menunjukkan fitur-fitur ini tidak memiliki hubungan linear yang kuat satu sama lain.

Pembagian Data: Data historis dibagi menjadi **set pelatihan (80%)** untuk melatih model dan **set pengujian (20%)** untuk mengevaluasi kinerjanya.






Machine Learning

Model Trip Time Prediction

Hasil evaluasi menunjukkan bahwa model dengan **Random Forest lebih baik dalam memprediksi durasi perjalanan** dibandingkan model dengan linear regression. Hal ini karna Random Forest lebih efektif dalam menangani interaksi kompleks antara fitur yang saling independen

Model	Metrik Evaluasi Model		
	MAE	RMSE	R-squared
Linear Regression	351.39 (5.86 Minutes)	509.55 (8.49 Minutes)	0.6834 (68.34%)
Random Forest	207.87 (3.46 Minutes)	308.09 (5.13 Minutes)	0.8842 (88.42%)


Model	Metrik Evaluasi Model		
	MAE	RMSE	R-squared
Random Forest after Tuning Parameters	198.46 (3.31 Minutes)	296.01 (4.93 Minutes)	0.8931 (89.31%)




Feature importance menunjukkan fitur mana yang paling berkontribusi terhadap model ini. **trip_miles merupakan feature paling penting, berkontribusi lebih dari 80%** untuk prediksi model. Dalam hal ini berarti Jarak tempuh adalah penentu utama durasi perjalanan. Semakin jauh jaraknya, biasanya semakin lama waktunya. Durasi perjalanan (trip_time) sangat tergantung pada jarak perjalanan (trip_miles). Model hampir bergantung dengan fitur ini untuk membuat prediksi, jadi kualitas data trip_miles sangat penting.

Data Visualization

2. Zona Penjemputan Paling Sibuk




2. Zona Tujuan/ Pengantaran Paling Sibuk



- **Distribusi Armada:** Membantu penyedia layanan (Uber/Lyft) untuk memprioritaskan penempatan armada di zona-zona paling sibuk, sehingga waktu tunggu penumpang dapat berkurang.
- **Strategi Pemasaran:** Pihak perusahaan dapat menargetkan promosi atau insentif khusus di zona-zona yang permintaannya tinggi dan mengevaluasi pada tempat-tempat sepi peminat.

Data Visualization

3. Analisis Jumlah Trip Harian (Maret 2025)




Summary	
Count:	31
SUM(pickup_hour)	
Sum:	9.924.897
Average:	320.157.97
Minimum:	190.827
Maximum:	464.489
Median:	308.778.00
SUM(trip_count)	
Sum:	675.515
Average:	21.790.81
Minimum:	14.656
Maximum:	30.000
Median:	21.435.00

Berdasarkan hasil analisis, tanggal 5, 20, 13, 26, 27 Maret 2025 merupakan hari dengan jumlah perjalanan terbanyak.

Hal ini bisa membantu **memprediksi penyebab lonjakan jumlah trip**, apa karna event tertentu, hari raya, libur, dan lain-lain untuk mengantisipasi kedepannya sehingga bisa mempersiapkan dengan lebih matang.


4. Analisis Frekuensi Durasi Perjalanan (Menit)

Dengan durasi **terbanyak berada di rentang 5-25 menit**. Hal ini menunjukkan bahwa fokus layanan dapat lebih dioptimalkan untuk segmen perjalanan jarak dekat. Dan **semakin jauh jumlah trip semakin sedikit**.



Data Visualization


5. Analisis Cluster Jarak Trip dengan Durasi Trip



Klaster-klaster yang terbentuk pada dasarnya hanya membagi perjalanan ke dalam **kategori: pendek-cepat, sedang-sedang, dan panjang-lama.**


6. Analisis Dominasi Layanan per Zona

Pola permintaan per zona menunjukkan dominasi yang bervariasi antar layanan. Ada zona-zona tertentu yang menjadi 'hotspot' bagi satu jenis layanan Uber, mengindikasikan **segmentasi pasar yang kuat berdasarkan wilayah.**




Data Visualization

7. Perbandingan Jarak Tempuh Harian



- Perencanaan dengan memprediksi rata-rata jarak perjalanan di hari-hari tertentu. Misalnya, mungkin jarak tempuh lebih pendek di akhir pekan.
- **Analisis Biaya:** Memungkinkan perusahaan untuk **mengelola biaya bahan bakar atau tarif** berdasarkan pola jarak tempuh harian.

8. Breakdown Komponen Pendapatan




struktur pendapatan kedua platform mirip, namun **UBER** lebih mengandalkan **tarif dasar perjalanan**, sementara **LYFT** distribusinya lebih **merata antara tarif dan pendapatan driver**

Data Visualization


9. Distribusi Penggunaan Layanan Per Zona

- Visualisasi ini (Treemap) menunjukkan **volume perjalanan di setiap zona**, di mana ukuran kotak mewakili jumlah perjalanan.
- Gambaran visual yang jelas tentang pasar terbesar dan terkecil.
- Rekomendasi Rute: Dapat digunakan untuk **menganalisis rute-rute populer** (dari zona padat ke zona padat lainnya) untuk mengoptimalkan layanan.


Zona Pengantaran



Zona Penjemputan



Data Visualization Dashboard Interaktif



Kegunaan dashboard ini untuk membantu menganbil keputusan :

- ➔ **Optimalisasi Strategi Harga dan Pendapatan** : Dengan mengambil keuntungan di wilayah2 yang ramai, menganalisa biaya-biaya yg besar, dan mencari cara mengurangi nya tanpa mengorbkan kualitas layanan da kerugian.
- ➔ **Peningkatan Efisiensi Operasional** : Mendistribuisikan armada ke wilayah yang ramai sehingga mengurangi waktu tunggu pelanggan,
- ➔ **Memahami pasar dan keunggulan kompetitor** : merancang strategi promosi, atau mencari tahu faktor kenapa pesaing mempunyai durasi lebih cepat dengan jarak yg sama,
- ➔ **Memperbaiki layanan** dengan mengidentifikasi area bermasalah dan **merencanakan ekspansi** .

Insight & Recommendation

Insight



1. Permintaan Layanan & Lokasi

- Analisis: Permintaan penjemputan sangat terkonsentrasi di pusat Manhattan.
- Implikasi: Ini menciptakan ketidakseimbangan operasional, di mana banyak pengemudi mungkin harus melakukan "perjalanan kosong" kembali ke area ramai.

2. Efisiensi Layanan

- Analisis: Waktu tunggu kendaraan WAV (berkebutuhan khusus) tetap wajar (rata-rata 2,6 menit), meskipun lebih lama dari kendaraan biasa. Selain itu, rasio keberhasilan shared ride mencapai 63%, tetapi bervariasi per zona.
- Implikasi: Ini menunjukkan adanya peluang untuk meningkatkan efisiensi dan profitabilitas melalui optimasi.

3. Model Machine Learning

- Analisis: Model Random Forest kami berhasil memprediksi waktu perjalanan (trip time) dengan akurat, mengungguli regresi linier.
- Implikasi: Prediksi ini sangat penting untuk efisiensi operasional, memungkinkan perkiraan waktu tiba yang lebih tepat dan strategi rute yang lebih baik.



Insight & Recommendation

Recommendation

1. Strategi Operasional: Pemerataan Driver

- Rekomendasi: Sebarkan pengemudi secara strategis ke zona-zona lain yang kurang ramai untuk mengurangi perjalanan kosong.
- Dasar Analisis: Data menunjukkan konsentrasi penjemputan yang tinggi di satu area, menciptakan inefisiensi.

2. Strategi Pemasaran: Kampanye Shared Ride

- Rekomendasi: Jalankan kampanye dan promosi yang menargetkan zona dengan tingkat keberhasilan shared ride yang rendah.
- Dasar Analisis: Meskipun rata-rata baik, ada variasi besar antar zona. Meningkatkan adopsi shared ride akan menghemat bahan bakar dan meningkatkan keuntungan per perjalanan.

3. Strategi Harga: Dinamisme & Insentif

- Rekomendasi: Terapkan pengaturan harga dinamis yang didukung oleh model prediksi, terutama pada hari atau acara khusus.
- Dasar Analisis: Model prediksi dapat mengidentifikasi kapan dan di mana permintaan akan meningkat, memungkinkan penetapan harga yang optimal.



Thank You
For Your Attention

